LAPORAN PROJECT UAS DATA SCIENCE

Perbandingan Model Regresi Linear, Random Forest, dan XGBoost dalam Prediksi Total Penjualan Berbasis Data Transaksi

Disusun Oleh:

Mirza Satrio Yudiarizky	2310512128
Pratama Firmansyah Maulana	2310512118
Anisa Bella Kayla	2310512110
Reza Aliyya Nasution	2310512100

PROGRAM STUDI S1 SISTEM INFORMASI
FAKULTAS ILMU KOMPUTER
UNIVERSITAS PEMBANGUNAN NASIONAL "VETERAN" JAKARTA

TAHUN 2025

DAFTAR ISI

DAFTAR ISI **2**
BAB I PENDAHULUAN **1**
1.1 Latar Belakang 1
1.2 Rumusan Masalah 1
1.3 Tujuan 1
1.4 Ruang Lingkup 1
BAB II DATA UNDERSTANDING & DATA CLEANING **2**
2.1 Deskripsi Dataset 2
2.2 Struktur dan Kualitas Data (EDA Level 1) 2
2.3 Konsistensi Data 2
2.4 Data Cleaning 2
BAB III EXPLORATORY DATA ANALYSIS (EDA) & INSIGHT **4**
3.1 Tren Penjualan Bulanan 4
3.2 Produk Terlaris 4
3.3 Pendapatan Berdasarkan Kategori Produk 5
3.4 Pendapatan Berdasarkan Hari 6
3.5 Metode Pembayaran 6
3.6 Lokasi Toko 7
3.7 Hubungan Harga dan Total Penjualan 8
3.8 Korelasi Variabel 9
BAB IV DATA PREPROCESSING & FEATURE ENGINEERING **10**
4.1 Tujuan Data Preprocessing 10
4.2 Encoding Data Kategorikal 10
4.3 Feature Engineering 11
4.4 Split Data 12
4.5 Scaling 12
BAB V MODELING & EVALUATION **13**
5.1 Model yang Digunakan 13
5.2 Evaluasi Model 13
5.3 Perbandingan Model 13
5.4 Perbandingan Model 15
5.5 Model Terbaik 16
BAB VI PENUTUP **17**
6.1 Kesimpulan 17
6.2 Implikasi Bisnis 17
6.3 Keterbatasan Penelitian 18
6.4 Rekomendasi 18
DAFTAR PUSTAKA **19**

BAB I
PENDAHULUAN

1.1 Latar Belakang

Perkembangan bisnis ritel menuntut perusahaan untuk mampu memanfaatkan data transaksi secara optimal. Data penjualan tidak hanya berfungsi sebagai arsip historis, tetapi juga sebagai sumber informasi strategis untuk memahami pola perilaku konsumen, tren penjualan, efektivitas diskon, serta performa produk dan lokasi toko. Oleh karena itu, diperlukan analisis data berbasis data science untuk menghasilkan insight yang dapat mendukung pengambilan keputusan bisnis.

Pada proyek ini digunakan dataset transaksi penjualan Instax yang berisi informasi produk, harga, kuantitas, diskon, metode pembayaran, lokasi toko, serta waktu transaksi. Analisis dilakukan mulai dari tahap pemahaman data, eksplorasi data, preprocessing, hingga pemodelan machine learning untuk memprediksi total penjualan.

1.2 Rumusan Masalah

1. Bagaimana karakteristik dan kualitas data transaksi penjualan Instax?
2. Pola dan tren apa yang dapat ditemukan dari data penjualan berdasarkan waktu, produk, kategori, metode pembayaran, dan lokasi?
3. Faktor apa saja yang paling berpengaruh terhadap total penjualan?
4. Model machine learning apa yang paling baik dalam memprediksi total penjualan?

1.3 Tujuan

1. Melakukan data understanding dan data cleaning pada dataset penjualan.
2. Menghasilkan insight bisnis melalui Exploratory Data Analysis (EDA).
3. Melakukan preprocessing dan feature engineering untuk kebutuhan pemodelan.
4. Membangun dan mengevaluasi model regresi untuk prediksi total penjualan.

1.4 Ruang Lingkup

Analisis dibatasi pada dataset transaksi penjualan Instax dengan target variabel berupa Total_Penjualan menggunakan pendekatan regresi.

BAB II
DATA UNDERSTANDING & DATA CLEANING

2.1 Deskripsi Dataset

Dataset yang digunakan merupakan data transaksi penjualan Instax yang terdiri dari beberapa atribut utama seperti:

- Tanggal transaksi
- Nama produk
- Kategori produk
- Harga satuan
- Jumlah pembelian (Qty)
- Diskon (IDR)
- Total penjualan
- Metode pembayaran
- Lokasi toko
- Hari transaksi

Dataset memiliki sejumlah baris dan kolom yang merepresentasikan transaksi penjualan pada periode tertentu.

2.2 Struktur dan Kualitas Data (EDA Level 1)

Tahap awal EDA dilakukan untuk memahami struktur data, yang meliputi:

- Pemeriksaan jumlah baris dan kolom
- Identifikasi tipe data setiap variabel
- Pemeriksaan missing values
- Deteksi duplikasi data
- Statistik deskriptif data numerik dan kategorikal

Hasil analisis menunjukkan bahwa:

- Tidak terdapat duplikasi data yang signifikan
- Missing values relatif kecil dan dapat ditangani
- Terdapat perbedaan tipe data pada kolom tanggal yang perlu dikonversi

2.3 Konsistensi Data

Dilakukan validasi konsistensi antara Harga_Satuan, Qty, Diskon_IDR, dan Total_Penjualan. Dari proses ini tidak ditemukan transaksi yang tidak konsisten.

2.4 Data Cleaning

Langkah pembersihan data meliputi:

- Menghapus kolom tidak relevan hasil pengecekan
- Menangani missing values dengan median (numerik) dan modus (kategorikal)

- Menghapus duplikasi
- Mengonversi kolom Tanggal ke tipe datetime
- Menyeragamkan penulisan data kategorikal

Output dari tahap ini adalah dataset bersih yang siap digunakan untuk analisis lanjutan.

BAB III
EXPLORATORY DATA ANALYSIS (EDA) & INSIGHT

3.1 Tren Penjualan Bulanan

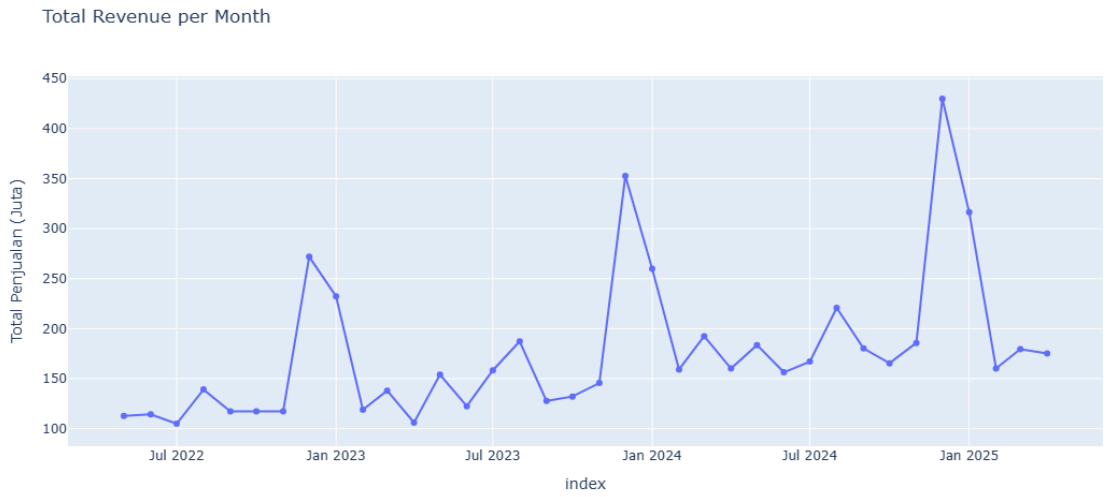

Grafik tersebut menunjukkan bahwa revenue dari penjualan produk Fujifilm Instax memiliki pola yang stabil dari tahun ke tahun. Meski ada penurunan dan kenaikan di beberapa bulan, pola waktunya selalu muncul di periode yang sama setiap tahunnya. Hal ini menunjukkan adanya seasonality yang cukup kuat.Grafik ini relevan untuk modeling karena pola musiman dan kenaikan-penurunan penjualan yang konsisten dari tahun ke tahun dapat membantu model memahami pola prediksi penjualan secara lebih akurat.

3.2 Produk Terlaris

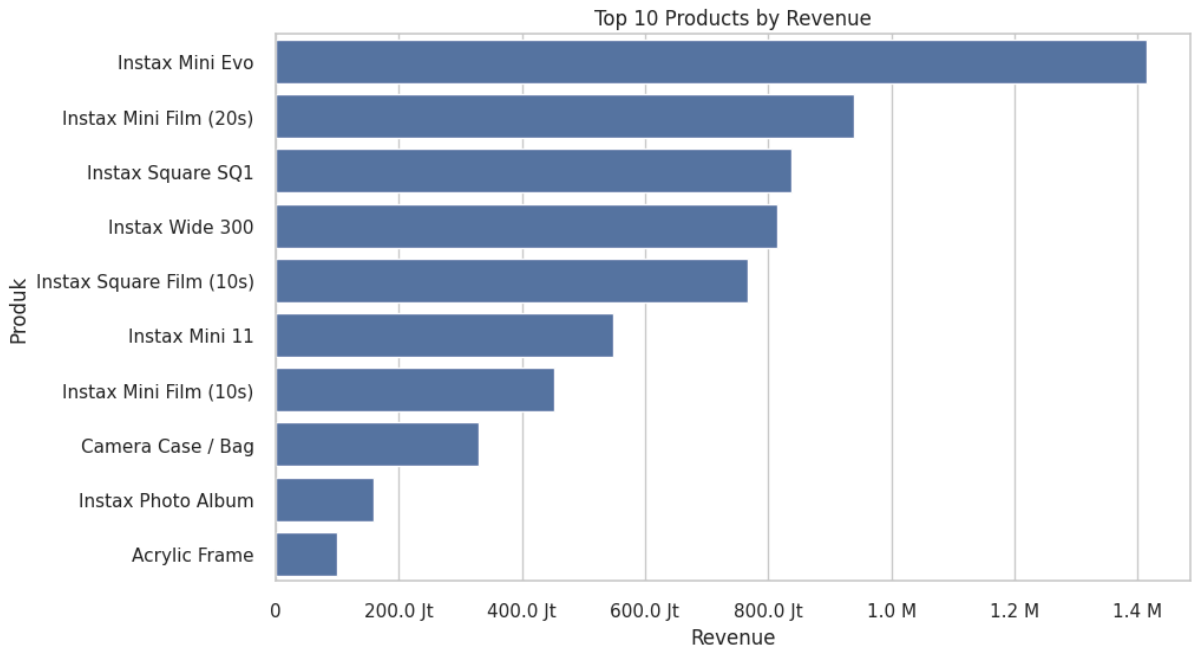

Grafik tersebut menunjukkan bahwa revenue produk-produk yang berada pada posisi top 5 jauh lebih tinggi dibandingkan produk lain, sehingga kualitas stok, ketersediaan barang, dan strategi pemasaran untuk produk pada posisi 6 dan di bawahnya perlu benar-benar diperhatikan agar penjualan tetap stabil. Informasi tentang produk dengan kontribusi revenue tertinggi dapat membantu model mengenali pola penjualan yang dipengaruhi oleh jenis produk, sehingga fitur kategori atau nama produk tetap relevan untuk meningkatkan akurasi prediksi.

3.3 Pendapatan Berdasarkan Kategori Produk

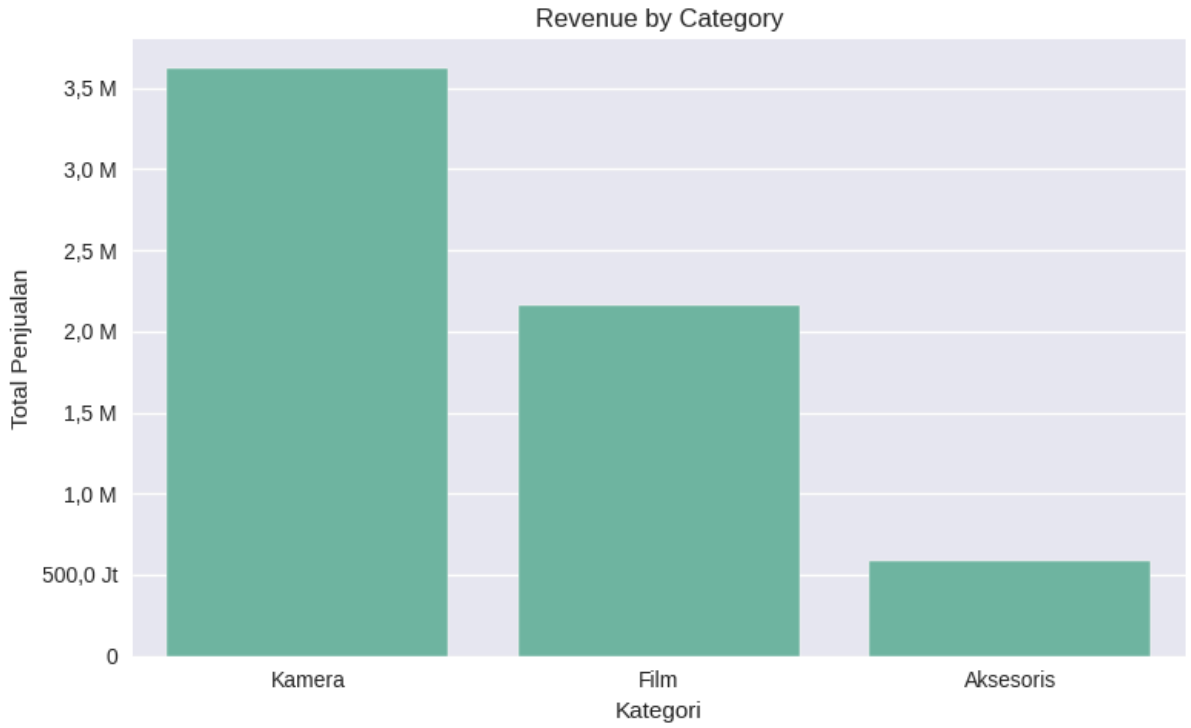

Grafik ini menunjukkan bahwa revenue dari penjualan kamera jauh mengungguli film dan aksesori, sehingga kategori ini menjadi core revenue stream dan perlu dijaga ketersediaan stok serta promo musiman untuk menjaga performanya tetap stabil. Informasi dari kategori produk dapat membantu model memahami pola penjualan di tiap segmen.

3.4 Pendapatan Berdasarkan Hari

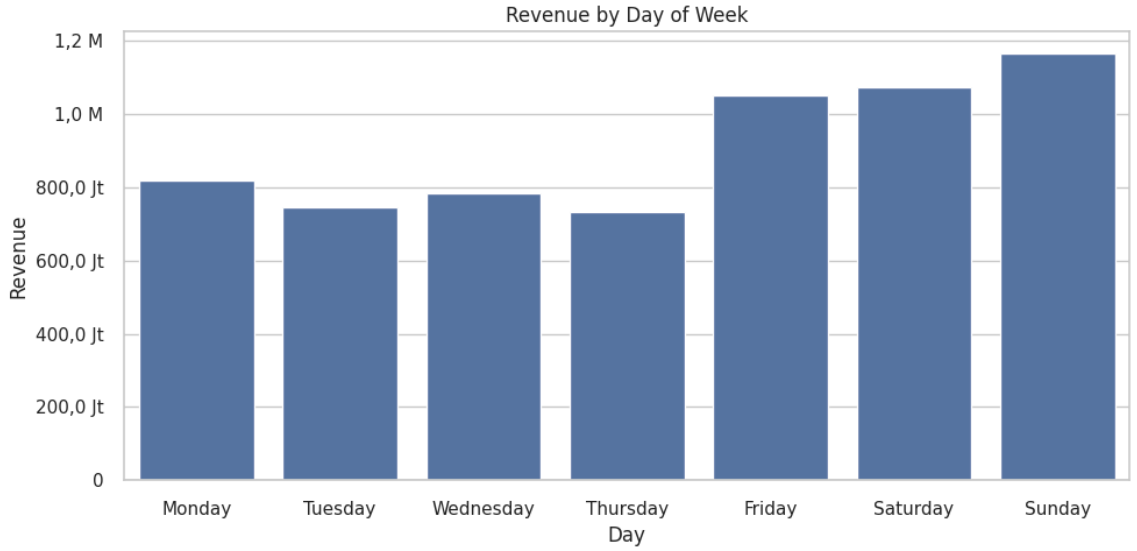

Grafik tersebut menunjukkan bahwa revenue cenderung meningkat saat weekend, yang mengindikasikan bahwa perilaku belanja konsumen naik ketika mereka memiliki waktu senggang. Dari insight ini, Fujifilm Instax bisa mempertimbangkan untuk menambah personel di offline store saat weekend agar pengalaman belanja pelanggan tetap nyaman meskipun store lebih ramai. Informasi pola harian membantu model memperkirakan lonjakan penjualan berdasarkan hari.

3.5 Metode Pembayaran

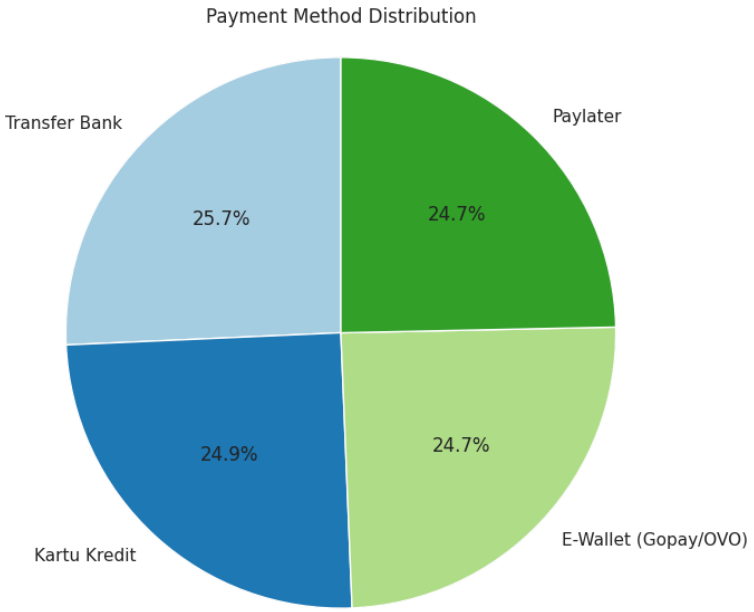

Grafik tersebut menunjukkan bahwa preferensi metode pembayaran pelanggan relatif seimbang tanpa ada satu metode pun yang mendominasi secara signifikan. Jadi, Fujifilm Instax perlu memastikan bahwa seluruh metode (Transfer Bank, Kartu Kredit, E-Wallet, Paylater) tetap tersedia dan berjalan lancar agar tidak menghilangkan potensi transaksi.

Metode pembayaran dapat dijadikan fitur kategorikal karena pola penggunaannya yang merata membantu model memahami preferensi transaksi tanpa bias berlebihan ke satu kelompok.

3.6 Lokasi Toko

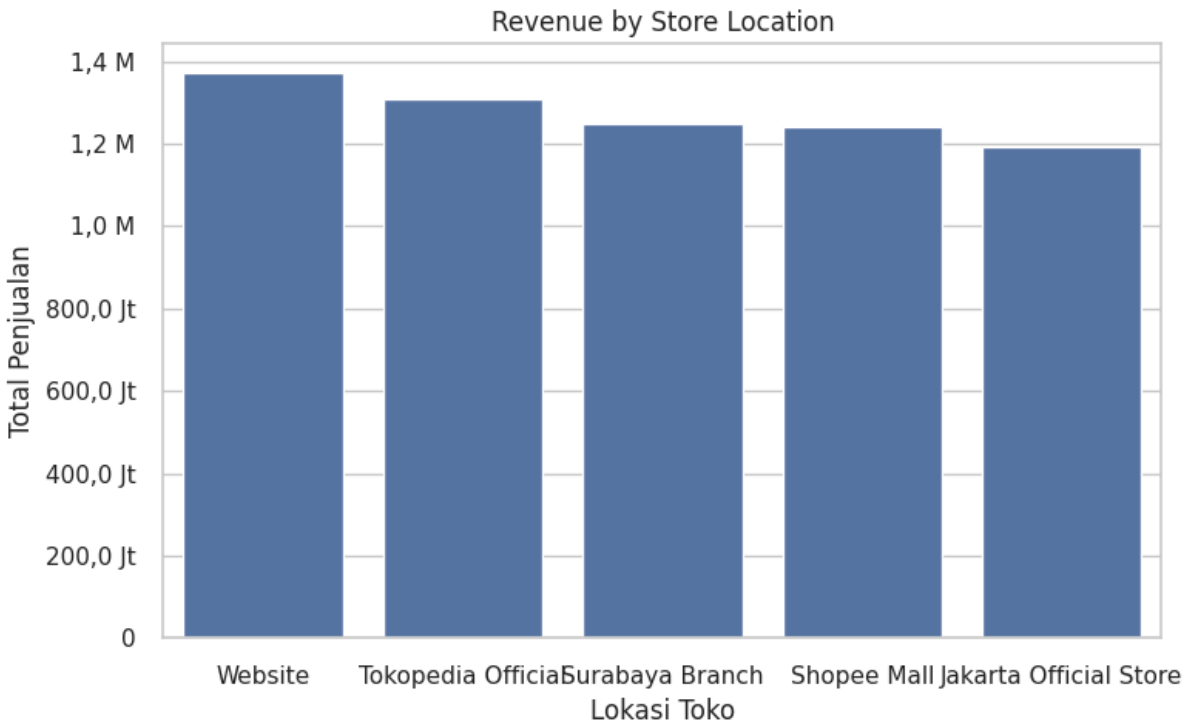

Dari grafik terlihat bahwa pendapatan tiap lokasi store relatif stabil, dengan beberapa lokasi selalu menghasilkan penjualan yang lebih tinggi dibandingkan lokasi lain. Pola yang konsisten ini membantu perusahaan menentukan prioritas penyaluran stok dan strategi promosi per lokasi.

3.7 Hubungan Harga dan Total Penjualan

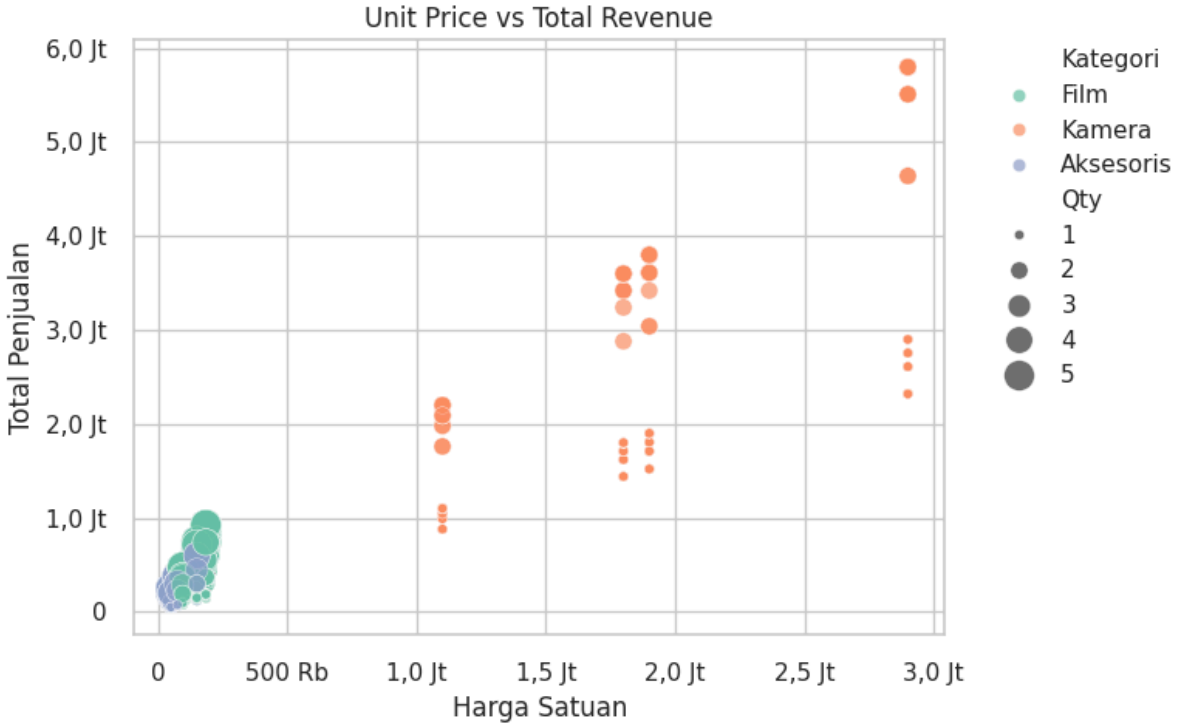

Grafik scatter ini memperlihatkan hubungan antara harga satuan, kuantitas pembelian, dan total revenue yang dihasilkan. Dari grafik tersebut kita dapat melihat bahwa kamera adalah produk dengan harga tinggi dan menjadi sumber revenue terbesar, meskipun quantity yang terjual sedikit. Sedangkan film dan aksesoris memiliki quantity pembelian besar namun revenue rendah. Variabel harga, kategori, dan qty punya pola yang jelas terhadap total penjualan, sehingga ketiganya sangat relevan sebagai predictor dalam model.

3.8 Korelasi Variabel

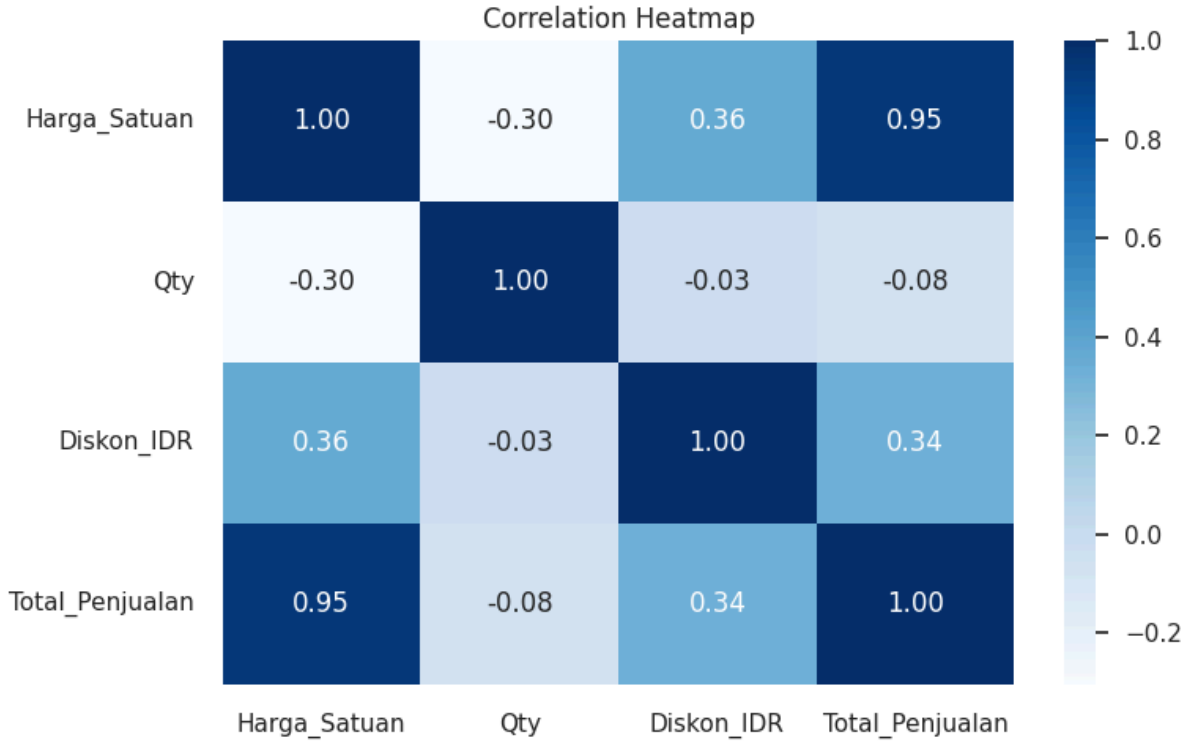

Heatmap menunjukkan bahwa Harga_Satuan memiliki korelasi sangat kuat dengan Total_Penjualan, menandakan bahwa perubahan harga langsung memengaruhi total revenue. Selain itu, Diskon_IDR juga memiliki korelasi yang cukup berarti, tapi tidak dominan dengan Total_Penjualan, sehingga besarnya diskon ikut mendorong peningkatan pendapatan. Sementara itu, Qty tidak memiliki korelasi kuat terhadap Total_Penjualan, mengindikasikan bahwa nominal revenue lebih dipengaruhi oleh harga produk daripada jumlah unit yang dibeli. Heatmap menunjukkan bahwa harga satuan adalah fitur paling kuat untuk memprediksi total penjualan sehingga sangat penting dimasukkan dalam model.

BAB IV
DATA PREPROCESSING & FEATURE ENGINEERING

4.1 Tujuan Data Preprocessing

Data preprocessing dilakukan untuk memastikan dataset berada dalam kondisi optimal sebelum digunakan pada tahap pemodelan machine learning. Proses ini bertujuan untuk mengubah data mentah menjadi data terstruktur, bebas bias, dan sesuai dengan kebutuhan algoritma regresi.

4.2 Encoding Data Kategorikal

```
# Label Encoding untuk kategori dengan banyak unique values
label_cols = ["Nama_Produk", "Lokasi_Toko"]
```

Label Encoding

- Digunakan untuk:
  - Nama_Produk
  - Lokasi_Toko
- Alasan: jumlah kategori banyak, sehingga lebih efisien.

```
# One-Hot Encoding untuk kategori kecil
onehot_cols = ["Kategori", "Metode_Bayar"]
```

One-Hot Encoding

- Digunakan untuk:
  - Kategori
  - Metode_Bayar
- Alasan: jumlah kategori sedikit, tidak memunculkan ordinal palsu.

Teknik encoding digunakan untuk mengubah data kategorikal menjadi bentuk numerik agar dapat diproses oleh algoritma machine learning. Label Encoding diterapkan pada variabel dengan jumlah kategori yang besar, sedangkan One-Hot Encoding digunakan pada variabel dengan kategori terbatas untuk menghindari kesalahan interpretasi ordinal.

4.3 Feature Engineering

```
# Feature date
df["Month"] = df["Tanggal"].dt.month
df["Day"] = df["Tanggal"].dt.day
df["Week"] = df["Tanggal"].dt.isocalendar().week

print("Date-based features created: Month, Day, Week")

#Pembuatan fitur Holiday_Flag berdasarkan daftar hari libur nasional
holiday_list = pd.to_datetime([
    "2023-01-01", "2023-06-01", "2023-12-25",
    "2024-01-01", "2024-06-01", "2024-12-25",
    "2025-01-01"
])

df["Holiday_Flag"] = df["Tanggal"].isin(holiday_list).astype(int)

print("Holiday Flag created.")

#Pembuatan fitur Diskon_Flag (1 jika ada diskon, 0 jika tidak)
df["Diskon_Flag"] = (df["Diskon_IDR"] > 0).astype(int)
print("Diskon_Flag created.")

#Pembuatan fitur Revenue_per_item (Total Penjualan ÷ Qty)
df["Revenue_per_item"] = df["Total_Penjualan"] / df["Qty"]
print("Revenue_per_item created.")
```

Fitur tambahan yang dibuat:

- Month, Day, Week dari kolom tanggal
  Fitur Month, Day, dan Week dibuat dari kolom tanggal transaksi untuk menangkap pola musiman dan tren waktu yang dapat memengaruhi total penjualan.
- Holiday_Flag
  Holiday_Flag digunakan untuk menandai transaksi yang terjadi pada hari libur nasional, karena hari libur berpotensi meningkatkan volume penjualan.
- Diskon_Flag
  Diskon_Flag menunjukkan apakah suatu transaksi memiliki diskon atau tidak, sehingga model dapat mempelajari pengaruh diskon terhadap total penjualan.

```
# Drop fitur leakage dari X
df = df.drop(columns=['Revenue_per_item'])
print("Revenue_per_item telah dihapus.")
```

Fitur Revenue_per_item dihapus karena berpotensi menyebabkan data leakage, mengingat fitur tersebut secara langsung diturunkan dari variabel target Total_Penjualan.

4.4 Split Data

```
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42
)
```

Dataset dibagi menjadi data training (80%) dan data testing (20%) menggunakan metode train-test split untuk memastikan evaluasi model dilakukan pada data yang belum pernah dilihat sebelumnya.

4.5 Scaling

```
from sklearn.preprocessing import StandardScaler

num_features = X_train.select_dtypes(include=['float64', 'int64']).columns

scaler = StandardScaler()
X_train[num_features] = scaler.fit_transform(X_train[num_features])
X_test[num_features] = scaler.transform(X_test[num_features])
```

Scaling dilakukan menggunakan StandardScaler untuk menstandarkan fitur numerik agar memiliki mean 0 dan standar deviasi 1. Hal ini penting untuk model berbasis jarak dan regresi agar tidak bias terhadap fitur dengan skala besar.

4.6 Dataset Final untuk Modeling

Hasil akhir preprocessing menghasilkan dataset yang telah melalui proses encoding, feature engineering, scaling, serta pembagian data training dan testing, sehingga siap digunakan pada tahap pemodelan machine learning.

BAB V
MODELING & EVALUATION

5.1 Model yang Digunakan

Pada tahap modeling, penelitian ini menggunakan tiga algoritma regresi, yaitu Linear Regression, Random Forest Regressor, dan XGBoost Regressor. Pemilihan ketiga model ini dilakukan untuk merepresentasikan pendekatan yang berbeda dalam pemodelan data, mulai dari model linear sederhana hingga model ensemble berbasis pohon keputusan. Linear Regression digunakan sebagai baseline model karena sifatnya yang sederhana dan mudah diinterpretasikan. Random Forest dan XGBoost dipilih karena keduanya merupakan model non-linear yang mampu menangkap hubungan kompleks antar fitur serta dikenal memiliki performa tinggi dalam prediksi data numerik. Dengan menggunakan ketiga model ini, perbandingan performa dapat dilakukan secara lebih objektif dan komprehensif.

5.2 Evaluasi Model

Evaluasi model dilakukan menggunakan tiga metrik utama, yaitu Mean Absolute Error (MAE), Root Mean Squared Error (RMSE), dan R^2 Score. MAE digunakan untuk mengukur rata-rata kesalahan absolut antara nilai aktual dan nilai prediksi sehingga mudah dipahami dalam satuan yang sama dengan target. RMSE memberikan penalti yang lebih besar terhadap error yang besar, sehingga sensitif terhadap prediksi yang menyimpang jauh. Sementara itu, R^2 Score digunakan untuk mengukur seberapa besar variasi data target yang dapat dijelaskan oleh model. Evaluasi dilakukan pada data training dan data testing untuk menilai kemampuan generalisasi masing-masing model.

5.3 Perbandingan Model

1. Hasil Evaluasi Linear Regression

```
=== Linear Regression Summary ===

--- Training Result ---
MAE  : 62126.61690768484
RMSE : 165424.3571704874
R²   : 0.9446895675347237

--- Testing Result ---
MAE  : 64785.66400985439
RMSE : 177213.31603895323
R²   : 0.9368775288235681
```

Gambar . Hasil Linear Regression

Model Linear Regression digunakan sebagai baseline karena sifatnya yang sederhana dan mudah diinterpretasikan. Pada data training, model ini menghasilkan nilai MAE sebesar 62.126, RMSE sebesar 165.424, dan R^2 sebesar 0,9447, yang menunjukkan bahwa sekitar 94% variasi total penjualan dapat dijelaskan oleh model. Pada data testing, performa sedikit menurun dengan MAE sebesar 64.785, RMSE sebesar 177.213, dan R^2 sebesar 0,9369. Selisih performa antara data training dan testing relatif kecil, sehingga model ini cukup stabil. Namun, nilai error yang masih tinggi mengindikasikan bahwa hubungan antara fitur dan target tidak sepenuhnya linear.

2. Hasil Evaluasi Random Forest Regressor

```
=== Random Forest Summary ===

--- Training Result ---
MAE  : 157.19479721425645
RMSE : 3670.397686440938
R²   : 0.9999727708309781

--- Testing Result ---
MAE  : 541.4998975829578
RMSE : 9067.666428954655
R²   : 0.9998347344401881
```

Gambar . Hasil Random Forest Regressor

Random Forest merupakan model ensemble berbasis decision tree yang mampu menangkap hubungan non-linear pada data. Pada data training, model ini menunjukkan performa yang sangat baik dengan MAE sebesar 157, RMSE sebesar 3.670, dan R^2 sebesar 0,99997, menandakan kemampuan fit yang sangat tinggi. Pada data testing, performa tetap konsisten dengan MAE sebesar 541, RMSE sebesar 9.067, dan R^2 sebesar 0,99983. Perbedaan error antara training dan testing masih dalam batas wajar, sehingga model ini tidak menunjukkan indikasi overfitting yang berlebihan. Hal ini menandakan bahwa Random Forest mampu melakukan generalisasi dengan sangat baik terhadap data baru.

3. Hasil Evaluasi XGBoost Regressor

```
=== XGBoost Summary ===

--- Training Result ---
MAE  : 345.884765625
RMSE : 622.7210701831118
R²   : 0.9999992251396179

--- Testing Result ---
MAE  : 1116.5927734375
RMSE : 7708.2441580427385
R²   : 0.9998805522918701
```

Gambar . Hasil XGBoost

XGBoost merupakan model boosting yang mengoptimalkan kesalahan secara bertahap dan sangat efektif pada dataset kompleks. Pada data training, XGBoost menghasilkan MAE sebesar 345, RMSE sebesar 622, dan R^2 sebesar 0,99999, yang menunjukkan kemampuan prediksi hampir sempurna. Pada data testing, model ini tetap menunjukkan performa tinggi dengan MAE sebesar 1.116, RMSE sebesar 7.708, dan R^2 sebesar 0,99988. Meskipun nilai MAE testing lebih besar dibanding Random Forest, nilai RMSE lebih kecil, yang berarti kesalahan ekstrem (error besar) lebih terkendali. Hal ini menunjukkan bahwa XGBoost sangat kuat dalam menangani pola kompleks dan outlier pada data penjualan.

5.4 Perbandingan Model

```
                Model     Train MAE     Train RMSE  Train R²      Test MAE  \
0  Linear Regression  62126.616908  165424.357170  0.944690  64785.664010
1      Random Forest    157.194797    3670.397686  0.999973    541.499898
2            XGBoost    345.884766     622.721070  0.999999   1116.592773

       Test RMSE   Test R²
0  177213.316039  0.936878
1    9067.666429  0.999835
2    7708.244158  0.999881
```

Gambar . Perbandingan Model

Secara keseluruhan, Linear Regression memiliki performa paling rendah dibanding dua model lainnya, ditunjukkan oleh nilai error yang jauh lebih besar dan R^2 yang lebih kecil. Random Forest dan XGBoost sama-sama menunjukkan performa yang sangat unggul dengan nilai R^2 mendekati 1 pada data testing. Random Forest memiliki MAE testing paling kecil, yang berarti kesalahan rata-rata prediksi lebih rendah. Sementara itu, XGBoost memiliki RMSE testing lebih kecil, yang menandakan model ini lebih baik dalam mengurangi kesalahan besar.

5.5 Model Terbaik

Berdasarkan hasil evaluasi pada data testing, kedua model ensemble (Random Forest dan XGBoost) secara signifikan mengungguli Linear Regression. Jika fokus utama adalah meminimalkan kesalahan rata-rata (MAE), maka Random Forest Regressor merupakan pilihan terbaik. Namun, jika tujuan utama adalah akurasi keseluruhan dan stabilitas terhadap error besar (RMSE lebih kecil), maka XGBoost Regressor dapat dianggap sebagai model terbaik. Oleh karena itu, sesuai dengan hasil evaluasi dan karakteristik data penjualan yang kompleks dan non-linear, XGBoost Regressor layak dipilih sebagai model final untuk memprediksi total penjualan.

BAB VI
PENUTUP

6.1 Kesimpulan

Berdasarkan seluruh tahapan analisis data science yang telah dilakukan, mulai dari data understanding, exploratory data analysis (EDA), data preprocessing, feature engineering, hingga pemodelan machine learning, dapat disimpulkan bahwa dataset transaksi penjualan Instax memiliki potensi yang sangat baik untuk dianalisis dan dimanfaatkan dalam mendukung pengambilan keputusan bisnis. Setelah melalui proses data cleaning, dataset berada dalam kondisi yang lebih rapi, konsisten, serta memiliki tipe data yang sesuai sehingga layak digunakan untuk analisis lanjutan.

Hasil EDA menunjukkan bahwa pola penjualan dipengaruhi oleh berbagai faktor, seperti waktu transaksi, jenis dan kategori produk, metode pembayaran, serta lokasi toko. Pola-pola tersebut mengindikasikan bahwa perilaku konsumen dan performa penjualan memiliki kecenderungan tertentu dan tidak terjadi secara acak. Insight yang dihasilkan dari EDA menjadi dasar penting dalam pemilihan fitur dan pendekatan pemodelan yang digunakan pada tahap selanjutnya.

Tahap data preprocessing dan feature engineering berperan krusial dalam meningkatkan kualitas dataset. Penambahan fitur berbasis waktu, penanda hari libur, serta indikator diskon membantu model dalam menangkap pola penjualan yang lebih kompleks. Selain itu, penerapan teknik encoding dan scaling yang tepat serta penghapusan fitur yang berpotensi menyebabkan data leakage memastikan bahwa proses pelatihan model dilakukan secara valid dan adil.

Pada tahap pemodelan, beberapa algoritma regresi diterapkan untuk memprediksi total penjualan, yaitu Linear Regression, Random Forest Regressor, dan XGBoost Regressor. Berdasarkan hasil evaluasi menggunakan metrik MAE, RMSE, dan R^2, model berbasis ensemble menunjukkan performa yang lebih baik dibandingkan model linear. Secara khusus, XGBoost Regressor memberikan hasil prediksi paling optimal pada data testing, sehingga dapat disimpulkan sebagai model terbaik dalam penelitian ini.

6.2 Implikasi Bisnis

Hasil analisis dan pemodelan pada proyek ini memiliki beberapa implikasi bisnis yang penting, antara lain:

1. Perusahaan dapat memanfaatkan insight EDA untuk mengoptimalkan strategi penjualan, seperti fokus pada produk dan kategori dengan kontribusi pendapatan tertinggi.
2. Informasi pola penjualan berdasarkan waktu dan hari dapat digunakan untuk perencanaan stok, penjadwalan promosi, serta alokasi sumber daya toko secara lebih efektif.

3. Model prediksi total penjualan dapat dijadikan alat bantu dalam perencanaan target penjualan dan estimasi pendapatan di masa depan.

6.3 Keterbatasan Penelitian

Meskipun analisis telah dilakukan secara menyeluruh, penelitian ini masih memiliki beberapa keterbatasan, antara lain:

1. Dataset yang digunakan bersifat historis dan terbatas pada periode waktu tertentu, sehingga pola yang dihasilkan mungkin tidak sepenuhnya merepresentasikan kondisi di masa mendatang.
2. Faktor eksternal seperti kondisi ekonomi, tren pasar, dan strategi pemasaran yang lebih detail belum dimasukkan ke dalam model.
3. Proses hyperparameter tuning pada model masih dilakukan secara terbatas dan belum menggunakan pendekatan otomatis seperti GridSearch atau RandomizedSearch secara menyeluruh.

6.4 Rekomendasi

Berdasarkan hasil penelitian dan keterbatasan yang ada, beberapa rekomendasi yang dapat diberikan adalah sebagai berikut:

1. Mengembangkan analisis dengan menambahkan data eksternal, seperti data promosi, kampanye pemasaran, atau kondisi ekonomi, untuk meningkatkan akurasi model.
2. Melakukan hyperparameter tuning yang lebih mendalam agar performa model machine learning dapat ditingkatkan.
3. Mengimplementasikan model prediksi ke dalam sistem pendukung keputusan agar dapat digunakan secara real-time oleh pihak manajemen.
4. Melakukan evaluasi model secara berkala dengan data terbaru untuk memastikan model tetap relevan dan akurat.

Dengan adanya rekomendasi tersebut, diharapkan hasil dari proyek data science ini dapat memberikan kontribusi nyata dalam pengambilan keputusan bisnis dan pengembangan analisis data di masa mendatang.

DAFTAR PUSTAKA

1. Pandas Documentation
2. Scikit-Learn Documentation
3. XGBoost Documentation
4. Dataset Transaksi Penjualan Instax